



UNIVERSIDADE DE AVEIRO

DEPARTAMENTO DE ELECTRÓNICA, TELECOMUNICAÇÕES E
INFORMÁTICA

47022- ARQUITECTURA DE COMPUTADORES AVANÇADA

Home group assignment 2

Semi-Global Matching stereo processing using CUDA

8240 - MESTRADO INTEGRADO EM ENGENHARIA DE
COMPUTADORES E TELEMÁTICA

António Rafael da
Costa Ferreira
NMec: 67405

Rodrigo Lopes
da Cunha
NMec: 67800

Docentes: Nuno Lau e José Luís Azevedo

Janeiro de 2016
2015-2016

Conteúdos

1	Introdução	2
2	Exercício 1	3
	2.1 Cuda Kernel da função "determine_costs()"	3
3	Exercício 2	6
	3.1 Cuda Kernel(s) da função "iterate_direction_dirxpos_dev()" e das funções correspondentes a outras direcções	6
4	Exercício 3	17
	4.1 Cuda Kernel da função "inplace_sum_views()"	17
5	Exercício 4	19
	5.1 Cuda Kernel da função "create_disparity_view()"	19
6	Conclusão	20

1 Introdução

O trabalho proposto para a unidade curricular de Arquitetura de Computadores Avançada foi a implementação em CUDA para o processamento de um Semi-Global Matching.

Este programa tem como objetivo determinar a imagem de disparidade entre duas imagens idênticas mas de posições diferentes, como se de dois olhos se tratasse, uma vista com o olho da esquerda e outra com o olho da direita.

O relatório reflete todas as geometrias de kernel implementadas, formas de pensamento, métodos de como foram implementados os algoritmos, resultados, tutorial para correr o código elaborado, e por último a conclusão deste mesmo trabalho.

2 Exercício 1

2.1 Cuda Kernel da função "determine_costs()"

Neste primeiro exercício, era pedido que se desenvolvesse um kernel em CUDA que substituísse a função *determine_costs()*. Este exercício foi ainda realizado de duas maneira, uma utilizando a *global memory*, e outra onde se coloca as imagens e o valor de COSTS na *texture memory*.

Versão 1 - Global Memory




Figura 1:
Geometria do Kernel para a função *determine_costs()*

Nesta versão do kernel optou-se por uma geometria (Figura 1 constituída por uma grid de tamanho $(\text{ceil}(nx/32) \times \text{ceil}(ny/16))$) com blocos de 32 x 16 threads cada. Neste kernel, cada thread corresponde a um pixel da imagem, e cada um calcula o valor de custo, sendo este a diferença entre as imagens num determinado pixel.

Para a *global memory* utilizou-se o seguinte algoritmo para desenvolver o kernel:

```
__global__ void determine_costs_device(const int *left_image, const int *right_image,
int *costs,
const int nx, const int ny, const int disp_range)
{
    int i = blockIdx.x * blockDim.x + threadIdx.x;
    int j = blockIdx.y * blockDim.y + threadIdx.y;

    if (i < nx && j < ny)
```

```

{
  for ( int d = 0; d < disp_range; d++ ) {
    if ( i >= d ) {
      COSTS(i,j,d) = abs( LEFT_IMAGE(i,j) - RIGHT_IMAGE(i-d,j) );
    }
  }
}
}

```

Com esta implementação obtiveram-se os seguintes resultados:

```

aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ ./sgm
Host processing time: 5160.187500 (ms)
Device processing time: 5048.691406 (ms)
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ !./te
./testDiffs h_dbull.pgm d_dbull.pgm
images are identical
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ ./sgm -p 64
Host processing time: 19739.484375 (ms)
Device processing time: 19562.093750 (ms)
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ !./te
./testDiffs h_dbull.pgm d_dbull.pgm
images are identical

```

Figura 2:

Resultados obtidos utilizando global memory - versão 1

Versão 2 - Global Memory

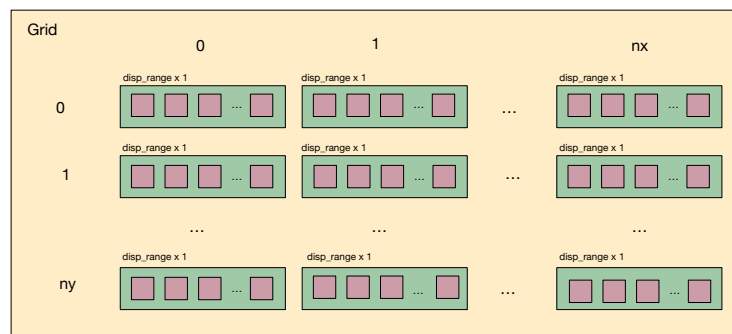


Figura 3:

Geometria do Kernel para a função `determine_costs()`

Na segunda versão deste kernel optou-se por uma geometria (Figura 3) constituída por uma grid de tamanho $n_x \times n_y$ com blocos de $\text{disp_range} \times 1$ threads cada. Neste kernel, cada thread corresponde a um valor de disparidade diferente e cada bloco corresponde a um pixel da imagem.

Os resultados desta nova implementação foram:

```
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ ./sgm
Host processing time: 5057.642578 (ms)
Device processing time: 5044.949219 (ms)
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ !./te
./testDiffs h_dbull.pgm d_dbull.pgm
images are identical
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ ./sgm -p 64
Host processing time: 19576.736328 (ms)
Device processing time: 19501.994141 (ms)
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ !./te
./testDiffs h_dbull.pgm d_dbull.pgm
images are identical
```

Figura 4:
Resultados obtidos utilizando global memory - versão 2

Como os resultados das duas versões não diferem muito, e há casos em que um é melhor e outros em que é pior, então, nos próximos exercícios que utilizam este kernel em memória global, será utilizada a versão 1.

TEXTURE MEMORY CODIGO E RESULTADOS

3 Exercício 2

3.1 Cuda Kernel(s) da função "iterate_direction_dirxpos_dev()" e das funções correspondentes a outras direcções

Para este exercício foram implementadas duas versões para a utilização de *global memory*, sendo a versão 2 (otimizada) utilizada na utilização da *shared memory*.

Global Memory - Versão 1

Nesta versão, foram criadas duas geometrias apenas, sendo que uma diz respeito às iterações nas direcções em x, e outra em y, visto que tanto para o lado positivo como para o negativo a geometria era idêntica.




Figura 5:

Geometria do Kernel para as funções `iterate_direction_dirxpos()` e `iterate_direction_dirxneg()`

Como podemos ver na figura 5, a grid é composta por $\text{ceil}(ny/32)$ blocos, cada bloco composto por 32 threads, sendo cada uma responsável pela linha em x onde está inserida para cálculo dos respetivos paths.

Esta operação tem de ser efetuada sequencialmente pois o pixel seguinte depende sempre do anterior, pelo que se recorreu à seguinte implementação para o kernel *iterate_direction_dirxpos()* e para o kernel *iterate_direction_dirxneg()*:

```
__global__ void iterate_direction_dirxpos_dev(const int dirx, const int *left_image,
                                             const int* costs, int *accumulated_costs,
                                             const int nx, const int ny, const int disp_range ){

    int i = 0;
    int j = blockIdx.y * blockDim.y + threadIdx.y;
    if(j < ny){

        for ( int d = 0; d < disp_range; d++ ) {
            ACCUMULATED_COSTS(0,j,d) += COSTS(0,j,d);
        }

        for(i = 1; i<nx; i++){
            evaluate_path_dev( &ACCUMULATED_COSTS(i-dirx,j,0),
                              &COSTS(i,j,0),
                              abs(LEFT_IMAGE(i,j)-LEFT_IMAGE(i-dirx,j)) ,
                              &ACCUMULATED_COSTS(i,j,0), nx, ny, disp_range);
        }
    }
}

__global__ void iterate_direction_dirxneg_dev(const int dirx, const int *left_image,
                                             const int* costs, int *accumulated_costs,
                                             const int nx, const int ny, const int disp_range )
{
    int i = nx-1;
    int j = blockIdx.y * blockDim.y + threadIdx.y;

    if(j < ny){

        for ( int d = 0; d < disp_range; d++ ) {
            ACCUMULATED_COSTS(nx-1,j,d) += COSTS(nx-1,j,d);
        }

        for(i = nx-2; i >= 0; i--){
            evaluate_path_dev( &ACCUMULATED_COSTS(i-dirx,j,0),
                              &COSTS(i,j,0),
                              abs(LEFT_IMAGE(i,j)-LEFT_IMAGE(i-dirx,j)) ,
                              &ACCUMULATED_COSTS(i,j,0), nx, ny, disp_range );
        }
    }
}
```


No caso da direção ser em y, então seguiu-se o mesmo pensamento que em x, obtendo a seguinte geometria:




Figura 6:

Geometria do Kernel para as funções `iterate_direction_dirypos()` e `iterate_direction_diryneg()`

Tal como apresentado na figura, neste caso a geometria é composta por uma grid de tamanho $\text{ceil}(ny/32)$ blocos, cada um composto por 32 threads, onde cada uma volta a ser responsável pelo cálculo do respetivo caminho de todos os pixeis daquela coluna.

Esta geometria volta a aplicar-se às direções positivas e negativa da mesma maneira tal como em x.

Foi então desenvolvido o seguinte código para os kernels `iterate_direction_dirypos()` e `iterate_direction_diryneg()`:

```
__global__ void iterate_direction_dirypos_dev(const int diry, const int *left_image,
                                             const int* costs, int *accumulated_costs,
                                             const int nx, const int ny, const int disp_range )
{
    int i = blockIdx.x * blockDim.x + threadIdx.x;
    int j = 0;
    if(i < nx){
        for ( int d = 0; d < disp_range; d++ ) {
            ACCUMULATED_COSTS(i,0,d) += COSTS(i,0,d);
        }
        for(j = 1; j<ny; j++){
            evaluate_path_dev( &ACCUMULATED_COSTS(i,j-diry,0),
                             &COSTS(i,j,0),
                             abs(LEFT_IMAGE(i,j)-LEFT_IMAGE(i,j-diry)),
                             &ACCUMULATED_COSTS(i,j,0), nx, ny, disp_range );
        }
    }
}

__global__ void iterate_direction_diryneg_dev(const int diry, const int *left_image,
                                             const int* costs, int *accumulated_costs,
                                             const int nx, const int ny, const int disp_range )
{
    int i = blockIdx.x * blockDim.x + threadIdx.x;
    int j = ny-1;
    if(i < nx){
        for ( int d = 0; d < disp_range; d++ ) {
            ACCUMULATED_COSTS(i,ny-1,d) += COSTS(i,ny-1,d);
        }
    }
}
```

```

    for(j = ny-2; j >= 0; j--){
        evaluate_path_dev( &ACCUMULATED_COSTS(i,j-dir_y,0),
                           &COSTS(i,j,0),
                           abs(LEFT_IMAGE(i,j)-LEFT_IMAGE(i,j-dir_y)),
                           &ACCUMULATED_COSTS(i,j,0) , nx, ny, disp_range);
    }
}

```

Nesta primeira versão, os resultados obtidos foram os seguintes:

```

aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex2_p2_67405_67800_global$ ./sgm
Host processing time: 5044.548340 (ms)
Device processing time: 4754.518066 (ms)
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex2_p2_67405_67800_global$ !./te
./testDiffs h_dbull.pgm d_dbull.pgm
images are identical
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex2_p2_67405_67800_global$ ./sgm -p 64
Host processing time: 19286.228516 (ms)
Device processing time: 17583.138672 (ms)
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex2_p2_67405_67800_global$ !./te
./testDiffs h_dbull.pgm d_dbull.pgm
images are identical

```

Figura 7:

Resultados obtidos utilizando a versão 1 com global memory

Notaram-se algumas melhorias, contudo é possível melhorar o speedup, e para isso recorreu-se a uma segunda versão, desenvolvida com o apoio da leitura do artigo ¹ fornecido pelos professores.

¹ Real-time Stereo Vision: Optimizing Semi-Global Matching, Matthias Michael, Jan Salmen, Johannes Stallkamp, and Marc Schlipsing, IEEE Intelligent Vehicles Symposium pp 1197-1202, 2013

Global Memory - Versão 2

Nesta segunda versão, decidiu-se alterar a geometria do kernel, de forma a que agora cada thread fosse responsável por um único valor de disparidade num path. Para isso a geometria criada para x foi a seguinte:




Figura 8:

Geometria do Kernel para as funções `iterate_direction_dirxpos()` e `iterate_direction_dirxneg()`

A grid passa a ser composta por `ny` blocos, cada um com um número de threads igual ao *disparity range*. Passa então a existir um bloco para cada linha em `x`, composto por threads, onde cada uma corresponde a um valor de disparidade diferente.

A implementação destes dois kernels foi efetuada através do seguinte algoritmo:

```
__global__ void iterate_direction_dirxpos_dev(const int dirx, const int *left_image,
                                             const int* costs, int *accumulated_costs,
                                             const int nx, const int ny, const int disp_range ){

    int i = threadIdx.x;
    int j = blockIdx.y * blockDim.y + threadIdx.y;
    if(i < disp_range && j<ny){
        ACCUMULATED_COSTS(0,j,i) += COSTS(0,j,i);
    }
}
```

```

    __syncthreads();

    for(int l = 1; l<nx;l++){
        evaluate_path_dev( &ACCUMULATED_COSTS(l-dirx,j,0),
                           &COSTS(l,j,0),
                           abs(LEFT_IMAGE(l,j)-LEFT_IMAGE(l-dirx,j)) ,
                           &ACCUMULATED_COSTS(l,j,0), nx, ny, disp_range, i);
        __syncthreads();
    }
}

__global__ void iterate_direction_dirxneg_dev(const int dirx, const int *left_image,
                                              const int* costs, int *accumulated_costs,
                                              const int nx, const int ny, const int disp_range )
{
    int i = threadIdx.x;
    int j = blockIdx.y * blockDim.y + threadIdx.y;

    if(i < disp_range && j < ny){
        ACCUMULATED_COSTS(nx-1,j,i) += COSTS(nx-1,j,i);

        __syncthreads();

        for(int l = nx-2; l >= 0; l--){
            evaluate_path_dev( &ACCUMULATED_COSTS(l-dirx,j,0),
                               &COSTS(l,j,0),
                               abs(LEFT_IMAGE(l,j)-LEFT_IMAGE(l-dirx,j)) ,
                               &ACCUMULATED_COSTS(l,j,0), nx, ny, disp_range, i);
            __syncthreads();
        }
    }
}

```

No caso da direção ser em y, a geometria utilizada foi a seguinte:




Figura 9:

Geometria do Kernel para as funções `iterate_direction_dirypos()` e `iterate_direction_diryneg()`

Nesta situação, a grid é composta por nx blocos, cada um um número de threads igual ao disparity range, onde cada thread, tal como em x, é responsável por um valor de disparidade diferente.

A implementação dos kernels correspondentes a esta geometria é a seguinte:

```
__global__ void iterate_direction_dirypos_dev(const int diry, const int *left_image,
                                              const int* costs, int *accumulated_costs,
                                              const int nx, const int ny, const int disp_range )
{
    int i = blockIdx.x * blockDim.x + threadIdx.x;
    int j = threadIdx.y;
    if(j < disp_range && i < nx){
        ACCUMULATED_COSTS(i,0,j) += COSTS(i,0,j);
        __syncthreads();

        for(int l = 1; l<ny; l++){
            evaluate_path_dev( &ACCUMULATED_COSTS(i,l-diry,0),
                              &COSTS(i,l,0),
                              abs(LEFT_IMAGE(i,l)-LEFT_IMAGE(i,l-diry)),
                              &ACCUMULATED_COSTS(i,l,0), nx, ny, disp_range, j);
            __syncthreads();
        }
    }
}

__global__ void iterate_direction_diryneg_dev(const int diry, const int *left_image,
                                              const int* costs, int *accumulated_costs,
                                              const int nx, const int ny, const int disp_range )
{
    int i = blockIdx.x * blockDim.x + threadIdx.x;
    int j = threadIdx.y;
    if(j < disp_range && i < nx){
```

```

ACCUMULATED_COSTS(i , ny-1, j) += COSTS(i , ny-1, j);
__syncthreads();

for(int l = ny-2; l >= 0; l--){
    evaluate_path_dev( &ACCUMULATED_COSTS(i , l-dir_y , 0) ,
                      &COSTS(i , l , 0) ,
                      abs(LEFT_IMAGE(i , l)-LEFT_IMAGE(i , l-dir_y)) ,
                      &ACCUMULATED_COSTS(i , l , 0) , nx, ny, disp_range , j );
    __syncthreads();
}
}
}

```

Para que a implementação desta segunda versão funcionasse foi necessário recorrer ao comando `__syncthreads()`, de forma a que todas as threads esperassem umas pelas outras quando chegavam ao ponto onde este comando se encontra colocado, garantindo assim que tudo era feito sequencialmente, e posteriormente utilizado de maneira correta quando se recorresse à shared memory. Foi ainda necessário efetuar alterações no código da função `evaluate_path()` para que agora dentro deste apenas calculasse o valor necessário para aquele valor de disparidade, ficando assim:

```

__device__ void evaluate_path_dev(const int *prior , const int *local ,
                                int path_intensity_gradient , int *curr_cost ,
                                const int nx, const int ny, const int disp_range, const int d)
{
    memcpy(curr_cost , local , sizeof(int)*disp_range);

    int e_smooth = NPP_MAX_16U;

    for ( int d_p = 0; d_p < disp_range; d_p++ ) {
        if ( d_p - d == 0 ) {
            // No penalty
            e_smooth = MMIN(e_smooth, prior[d_p]);
        } else if ( abs(d_p - d) == 1 ) {
            // Small penalty
            e_smooth = MMIN(e_smooth, prior[d_p]+PENALTY1);
        } else {
            // Large penalty
            e_smooth =
                MMIN(e_smooth, prior[d_p] +
                    MMAX(PENALTY1,
                        path_intensity_gradient ? PENALTY2/path_intensity_gradient : PENALTY2));
        }
    }

    curr_cost[d] += e_smooth;

    int min = NPP_MAX_16U;

    for ( int d_s = 0; d_s < disp_range; d_s++ ) {
        if ( prior[d_s]<min ) min=prior[d_s];
    }
}

```

```
}    curr_cost[d] == min;  
}
```

Com esta nova implementação, a melhoria no speedup foi brutal, melhorando bastante os resultados:

```
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex2_p2_67405_67800_globalv2$ ./sgm  
Host processing time: 5412.062988 (ms)  
Device processing time: 597.425415 (ms)  
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex2_p2_67405_67800_globalv2$ !./te  
./testDiffs h_dbull.pgm d_dbull.pgm  
Images are identical  
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex2_p2_67405_67800_globalv2$ ./sgm -p 64  
Host processing time: 20342.712891 (ms)  
Device processing time: 1224.891968 (ms)  
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex2_p2_67405_67800_globalv2$ !./te  
./testDiffs h_dbull.pgm d_dbull.pgm  
Images are identical
```

Figura 10:

Resultados obtidos utilizando a versão 2 com global memory

Para melhorar ainda mais estes resultados passou-se a utilizar a *shared memory* para o cálculo do path.

Esta versão 2 será a utilizada nos exercícios seguintes quando se utilizar apenas memória global.

Shared Memory

Visto que as threads na versão 2 eram executadas em paralelo, e que existiam valores que todas partilhavam e necessitavam umas das outras para o cálculo dos mínimos, então decidiu-se que seria mais produtivo que as pesquisas fossem feitas na *shared memory*. Para isso, foi necessário criar um array de *shared memory* com `shared_memory_size` igual a `disparity_range*sizeof(int)`, onde cada índice do array corresponde a um valor de disparidade. Agora em vez de a pesquisa ser efetuada no array prior, passou a ser efetuada no shmem, como mostrado no código seguinte.

A maioria das alterações foi feita na função `evaluate_path()`, visto ser nesta que se efetuam todas as pesquisas necessárias para determinar o current cost e o minimo. Com isto a função ficou da seguinte forma:

```
__device__ void evaluate_path_dev(const int *prior, const int *local,
                                int path_intensity_gradient, int *curr_cost,
                                const int nx, const int ny, const int disp_range, const int d, int shmem[])
{
    memcpy(curr_cost, local, sizeof(int)*disp_range);

    int e_smooth = NPP_MAX_16U;

    for ( int d_p = 0; d_p < disp_range; d_p++ ) {
        if ( d_p - d == 0 ) {
            // No penalty
            e_smooth = MMIN(e_smooth, shmem[d_p]);
        } else if ( abs(d_p - d) == 1 ) {
            // Small penalty
            e_smooth = MMIN(e_smooth, shmem[d_p]+PENALTY1);
        } else {
            // Large penalty
            e_smooth =
                MMIN(e_smooth, shmem[d_p] +
                    MMAX(PENALTY1,
                        path_intensity_gradient ? PENALTY2/path_intensity_gradient : PENALTY2));
        }
    }

    curr_cost[d] += e_smooth;

    int min = NPP_MAX_16U;

    for ( int d_s = 0; d_s < disp_range; d_s++ ) {
        if ( shmem[d_s] < min ) min = shmem[d_s];
    }

    curr_cost[d] -= min;

    __syncthreads();

    shmem[d] = curr_cost[d];
}
```

Aqui foi também necessário colocar outra vez o comando `__syncthreads()`,

para que todas as threads apenas escrevessem na memória partilhada quando todas tivessem calculado o mínimo valor nesta.

Mais uma vez com esta nova implementação, os resultados voltaram a melhorar muito em relação à memória global:

```
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ ./sgm
Host processing time: 5214.775391 (ms)
Device processing time: 412.266907 (ms)
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ !./te
./testDiffs h_dbull.pgm d_dbull.pgm
images are identical
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ ./sgm -p 64
Host processing time: 20074.746094 (ms)
Device processing time: 1044.164551 (ms)
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ !./te
./testDiffs h_dbull.pgm d_dbull.pgm
images are identical
```

Figura 11:
Resultados obtidos utilizando shared memory

TEXTURE

4 Exercício 3

4.1 Cuda Kernel da função "inplace_sum_views()"

A função *inplace_sum_views*, tem como objectivo a soma de pixels de duas imagens. Para esta a geometria utilizada foi idêntica à da determinação de custos (Exercício 1), contudo possui uma pequena alteração, pois o número de colunas é agora correspondente a $\text{ceil}((nx * \text{disp_range}) / 32)$:




Figura 12:
Geometria do Kernel para a função *inplace_sum_views()*

Para a implementação deste kernel criou-se o seguinte algoritmo:

```
__global__ void inplace_sum_views_dev(int * im1, const int * im2,
                                     const int nx, const int ny, const int disp_range){

    int i = blockIdx.x * blockDim.x + threadIdx.x;
    int j = blockIdx.y * blockDim.y + threadIdx.y;
    int id = i + (j * (nx*disp_range));

    if(i < nx*disp_range && j < ny){
        int *im1_init = im1;
        im1 += id;
        im2 += id;
        if(im1 != (im1_init + (nx*ny*disp_range)) ){
            *im1 += *im2;
        }
    }
}
```

Posteriormente a esta implementação obtiveram-se os seguintes resultados com a utilização do exercício 2 em global memory, em shared memory e texture memory :

```
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex3_p2_67405_67800_globalv2$ ./sgm
Host processing time: 5133.879395 (ms)
Device processing time: 494.530609 (ms)
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex3_p2_67405_67800_globalv2$ !./te
./testDiffs h_dbull.pgm d_dbull.pgm
images are identical
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex3_p2_67405_67800_globalv2$ ./sgm -p 64
Host processing time: 19267.103516 (ms)
Device processing time: 1023.468994 (ms)
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex3_p2_67405_67800_globalv2$ !./te
./testDiffs h_dbull.pgm d_dbull.pgm
images are identical
```

Figura 13:
Resultados obtidos utilizando global memory

```
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ ./sgm
Host processing time: 5173.232910 (ms)
Device processing time: 317.796356 (ms)
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ !./te
./testDiffs h_dbull.pgm d_dbull.pgm
images are identical
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ ./sgm -p 64
Host processing time: 20000.353516 (ms)
Device processing time: 862.332642 (ms)
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm$ !./te
./testDiffs h_dbull.pgm d_dbull.pgm
images are identical
```

Figura 14:
Resultados obtidos utilizando shared memory

Mais uma vez, é possível verificar-se as melhorias nos resultados tanto a nível de memória global como de memória partilhada.

5 Exercício 4

5.1 Cuda Kernel da função "create_disparity_view()"

No 4º e último exercício era proposto a implementação de um kernel para a função *create_disparity_view*, que tem como objectivo a criação da imagem de disparidade originada pelo programa.

Global Memory

Para este kernel pensou-se numa geometria idêntica à da determinação de custos:




Figura 15:
Geometria do Kernel para a função *create_disparity_view()*

Constituída por uma grid de $\text{ceil}(nx/32)$ por $\text{ceil}(ny/16)$ blocos, cada um constituído por 32×16 threads, onde cada uma corresponde a um pixel da imagem final e calcula o índice do array de custos daquele pixel, multiplicando-o por 4.

Com a implementação deste exercício 4, todo o programa passou a ser corrido no device, não ficando nenhuma função a ser executada no host no que diz respeito à função *sgmDevice()*. Nesta fase começa-se a obter os valores finais de toda a implementação, contudo, estes valores variam consoante o tipo de memórias utilizadas. Iremos então mostrar os resultados para os vários tipos de memória, sendo que o que possui a texture memory, será o que contém os três tipos de memória e será o mais otimizado.

Utilizando global memory, obtiveram-se os seguintes resultados:

```
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex4_p2_67405_67800_globalv2$ ./sgm
Host processing time: 5117.731934 (ms)
Device processing time: 472.267731 (ms)
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex4_p2_67405_67800_globalv2$ !./te
./testDiffs h_dbull.pgm d_dbull.pgm
images are identical
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex4_p2_67405_67800_globalv2$ ./sgm -p 64
Host processing time: 20009.533203 (ms)
Device processing time: 972.145874 (ms)
aca0203@nikola:~/acomputadoresavancada/Trabalho 2/aca_sgm/ex4_p2_67405_67800_globalv2$ !./te
./testDiffs h_dbull.pgm d_dbull.pgm
images are identical
```

Figura 16:
Resultados obtidos utilizando global memory

Shared Memory

Para a utilização de shared memory nesta função, foi feito um update à geometria do kernel, passando esta agora por uma grid composta por $n_x \times n_y$ blocos, sendo que cada bloco corresponde a um pixel, e um bloco é composto por `disp_range` threads, de forma a que cada uma trabalhe com um valor de disparidade individualmente, e partilhem a sua informação umas para as outras. SHARED MEMORY

TEXTURE MEMORY

6 Conclusão

Este trabalho foi útil para assentar conhecimentos que não foram muito abordados nas aulas teóricas e práticas, contudo é um tema bastante interessante, pelo que se deveria considerar a possibilidade de dedicar mais uma aula prática para adquirir os conhecimentos necessários para efetuar este trabalho com menos dificuldades.

É também interessante ver a diferença dos tempos de execução do mesmo programa no device e no host, pois não se tinha a noção que seria um speedup tão elevado e que uma geometria, como foi o caso da versão 1 e 2 do exercício 2, pudesse ter tanto impacto neste mesmo speedup..

Foi um projeto que deu bastante gosto a realizar, devido ao desafio de conseguir reduzir sempre os tempos de execução e pela aprendizagem e conhecimentos adquiridos.